


# DETECCIÓN DE ESTADO DE CULTIVOS MEDIANTE REMOTE SENSING PARA MEJORA DEL DESPLIEGUE DE MEDIOS EN INCENDIOS FORESTALES

Alejandro Sáez Subero


Data Scientist - Corporación Nacional Forestal

[alexsaez1990@gmail.com](mailto:alexsaez1990@gmail.com)




# CONTEXTO

- La Corporación Nacional Forestal de Chile (CONAF), se encarga de la administración de los parques nacionales y de la gestión y combate de los incendios forestales.
- El Departamento de Investigación y Desarrollo, se centra en este último punto, siendo el encargado del despliegue de medios y análisis de incendios.
- En el despliegue de medios en una emergencia, una de las herramientas principales es el análisis del terreno mediante satélite.



# PROBLEMA

- Existen sistemas de detección de tipos de suelo
  - Bosque, urbano, pastizal, agua, cultivo...
- No diferencian el estado del cultivo.
- Es fundamental diferenciar si un cultivo esta verde o seco para prevenir la expansión del fuego y desplegar los medios de forma adecuada.





# OBJETIVO

- Desarrollo de un modelo propio que sea capaz de detectar cultivos sobre mapas de satélite en tiempo real.
- Que sea capaz de diferenciar si un cultivo está verde o está seco.



# ESTRUCTURA DEL PROYECTO

- Fase de desarrollo de prototipo (7 semanas)

Debido a la limitación de tiempo, en esta primera fase del proyecto se tratará de obtener una primera versión Beta, con un prototipo funcional que muestre el potencial que puede tener la herramienta tras un proceso de desarrollo completo.

## Sprint 1 - Búsqueda y definición de datasets



Búsqueda de datasets

🕒 5 de sep. - 7 de sep. ≡

Definición de opciones

🕒 8 de sep. - 12 de sep. ≡

+ Añada una tarjeta



## Sprint 2 - Análisis y preparación de los datos para el proceso de modelado



Validación de datos

🕒 13 de sep. - 15 de sep. ≡

EDA (Análisis exploratorio)

🕒 16 de sep. - 19 de sep. ≡

Pre - procesado

🕒 20 de sep. - 26 de sep. ≡

Estudio y lectura de documentación y papers



+ Añada una tarjeta



## Sprint 3 - Modelado y evaluación de modelos



Modelado

🕒 27 de sep. - 3 de oct. ≡

Evaluación

🕒 27 de sep. - 3 de oct. ≡

+ Añada una tarjeta



# S1. BÚSQUEDA Y DEFINICIÓN DE DATASETS

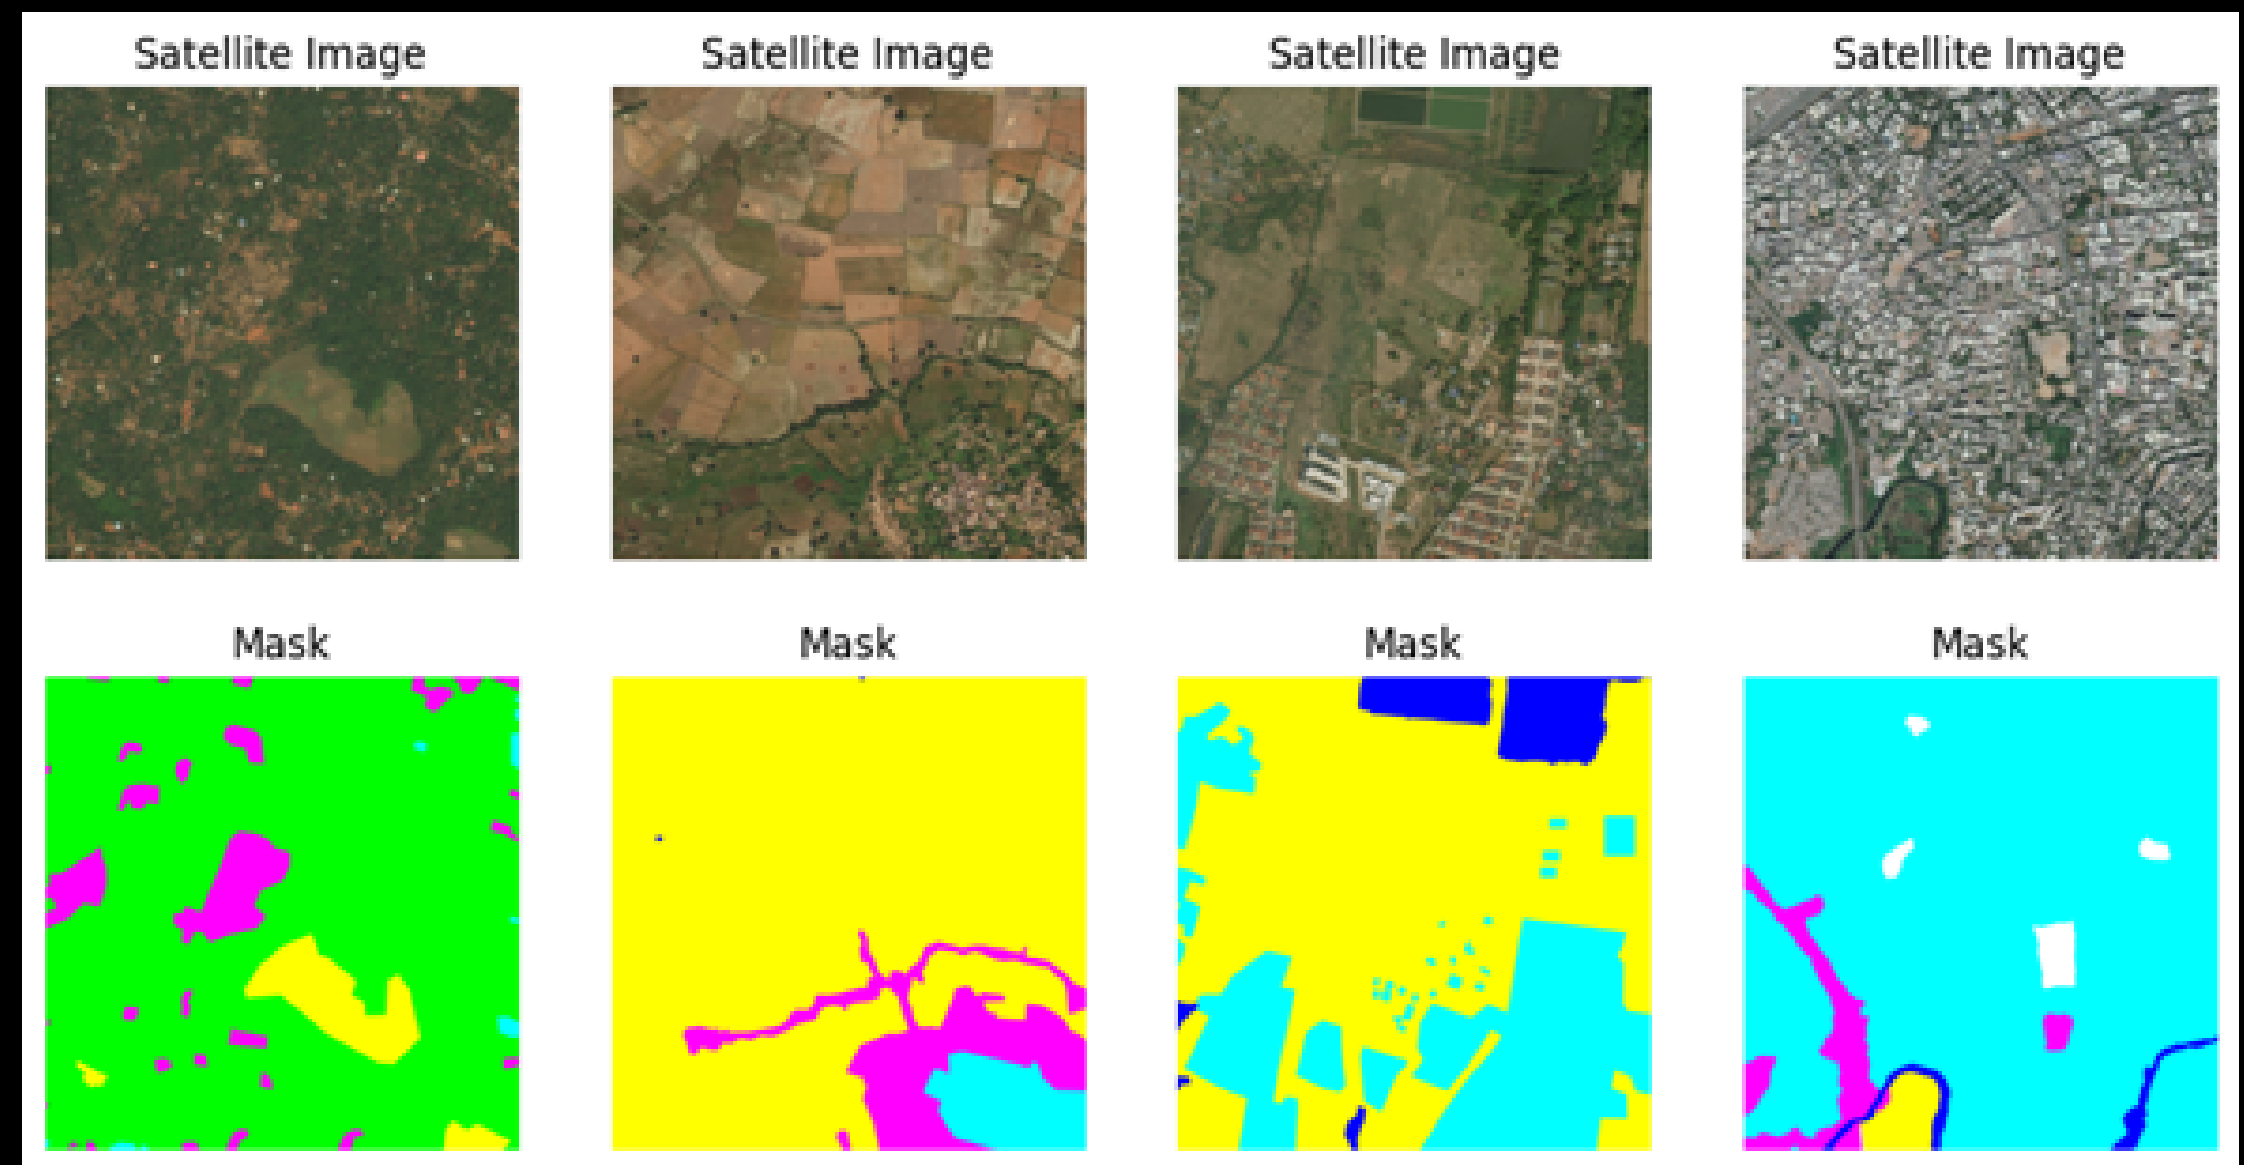
- Selección de datasets:
  - **Sentinelhub**
    - API Sentinel
    - Uso limitado
  - **EuroSAT dataset**
    - 27k imágenes jpg
    - 27k imágenes 13 bandas
  - **DeepGlobe dataset**
    - 803 imágenes jpg
    - 803 máscaras multilabel png
    - ~ 700 imágenes jpg sin etiquetar
    - 2048x2048 px.

Banda	Resolución Espacial	Longitud de onda central	Descripción
B1	60 m	443 nm	Ultra azul (Costa y Aerosol)
B2	10 m	490 nm	Azul
B3	10 m	560 nm	Verde
B4	10 m	665 nm	Rojo
B5	20 m	705 nm	Visible e Infrarrojo Cercano (VNIR)
B6	20 m	740 nm	Visible e Infrarrojo Cercano (VNIR)
B7	20 m	783 nm	Visible e Infrarrojo Cercano (VNIR)
B8	10 m	842 nm	Visible e Infrarrojo Cercano (VNIR)
B8a	20 m	865 nm	Rojo de borde (RedEdge)
B9	60 m	940 nm	Vapor de Agua
B10	60 m	1375 nm	Cirrus
B11	20 m	1610 nm	Onda Corta Infrarroja (SWIR)
B12	20 m	2190 nm	Onda Corta Infrarroja (SWIR)

# S2. ANÁLISIS Y PREPARACIÓN DE LOS DATOS PARA EL PROCESO DE MODELADO

## VALIDACIÓN DE DATOS DEEPGLOBE


- Ver notebook:  
*Validación\_muestras\_deepglobe.ipynb*





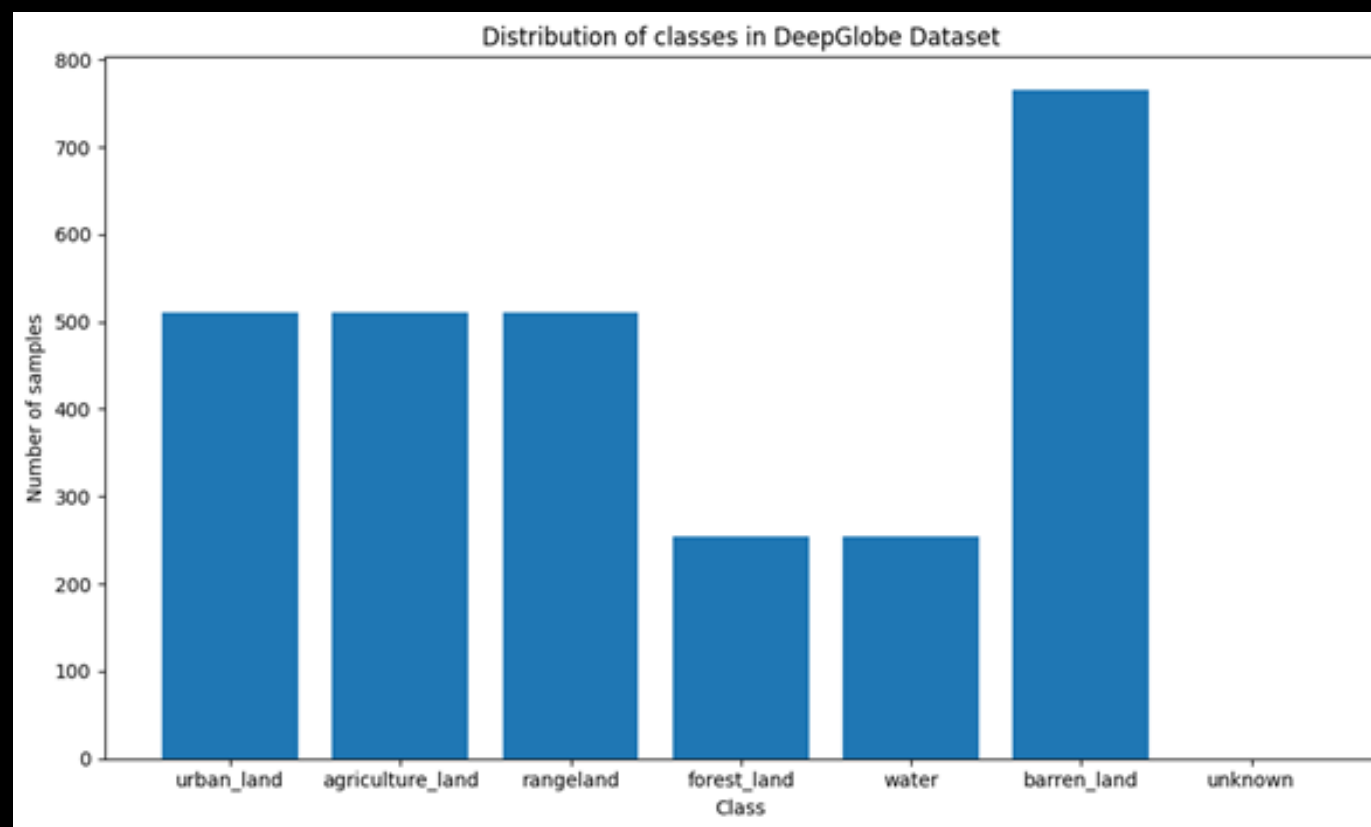


## S2. REQUERIMIENTOS TRAS OBSERVAR LOS DATOS


- Dos vías de trabajo:
    - Modelos de clasificación
    - Modelos de segmentación
  - Necesidad de obtener más imágenes:
    - Split de las originales de 2048x2048 a 128x128
    - Logramos obtener 256 tiles por cada imagen original
    - Ver **notebook**: *DeepGlobe\_TilesGeneration.ipynb*
  - Las imágenes no pueden ser multilabel.
    - K - Means
    - Determinar color dominante de cada máscara
    - Ver **notebook**: *Labeling\_images\_DeepGlobe.ipynb*
- 

## S2. ANÁLISIS EXPLORATORIO (EDA)

- Problema al dividir las imágenes originales:  
**¡Desbalanceo!**

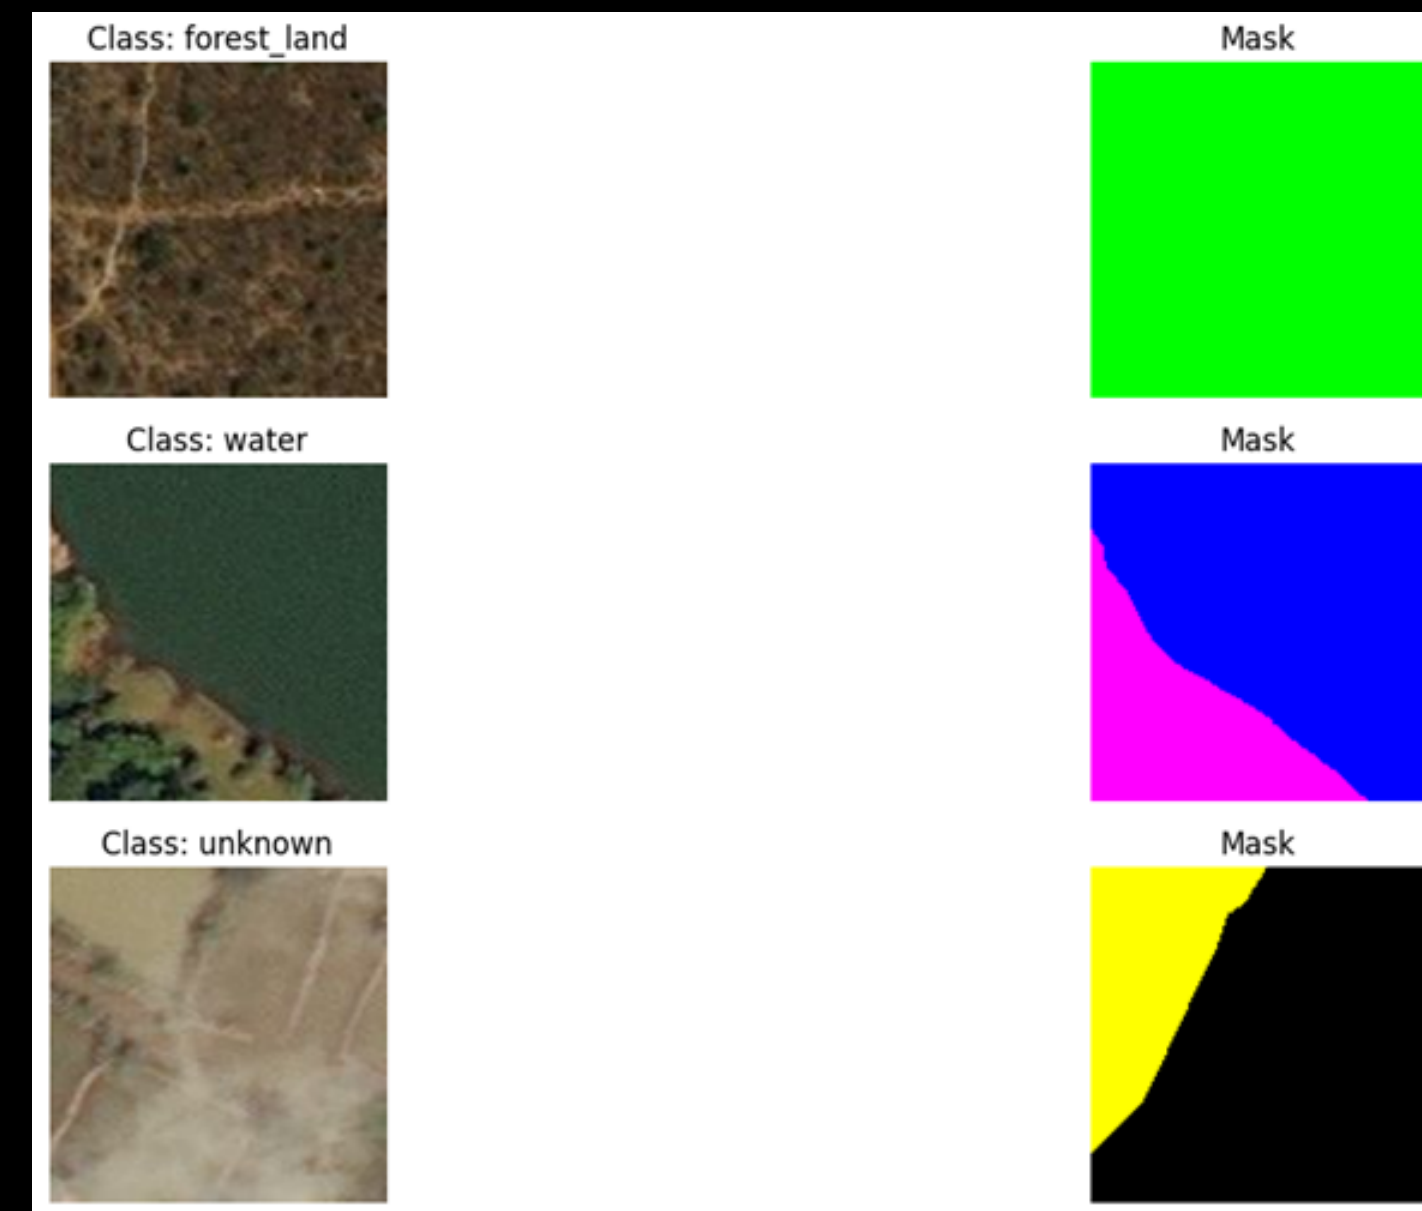
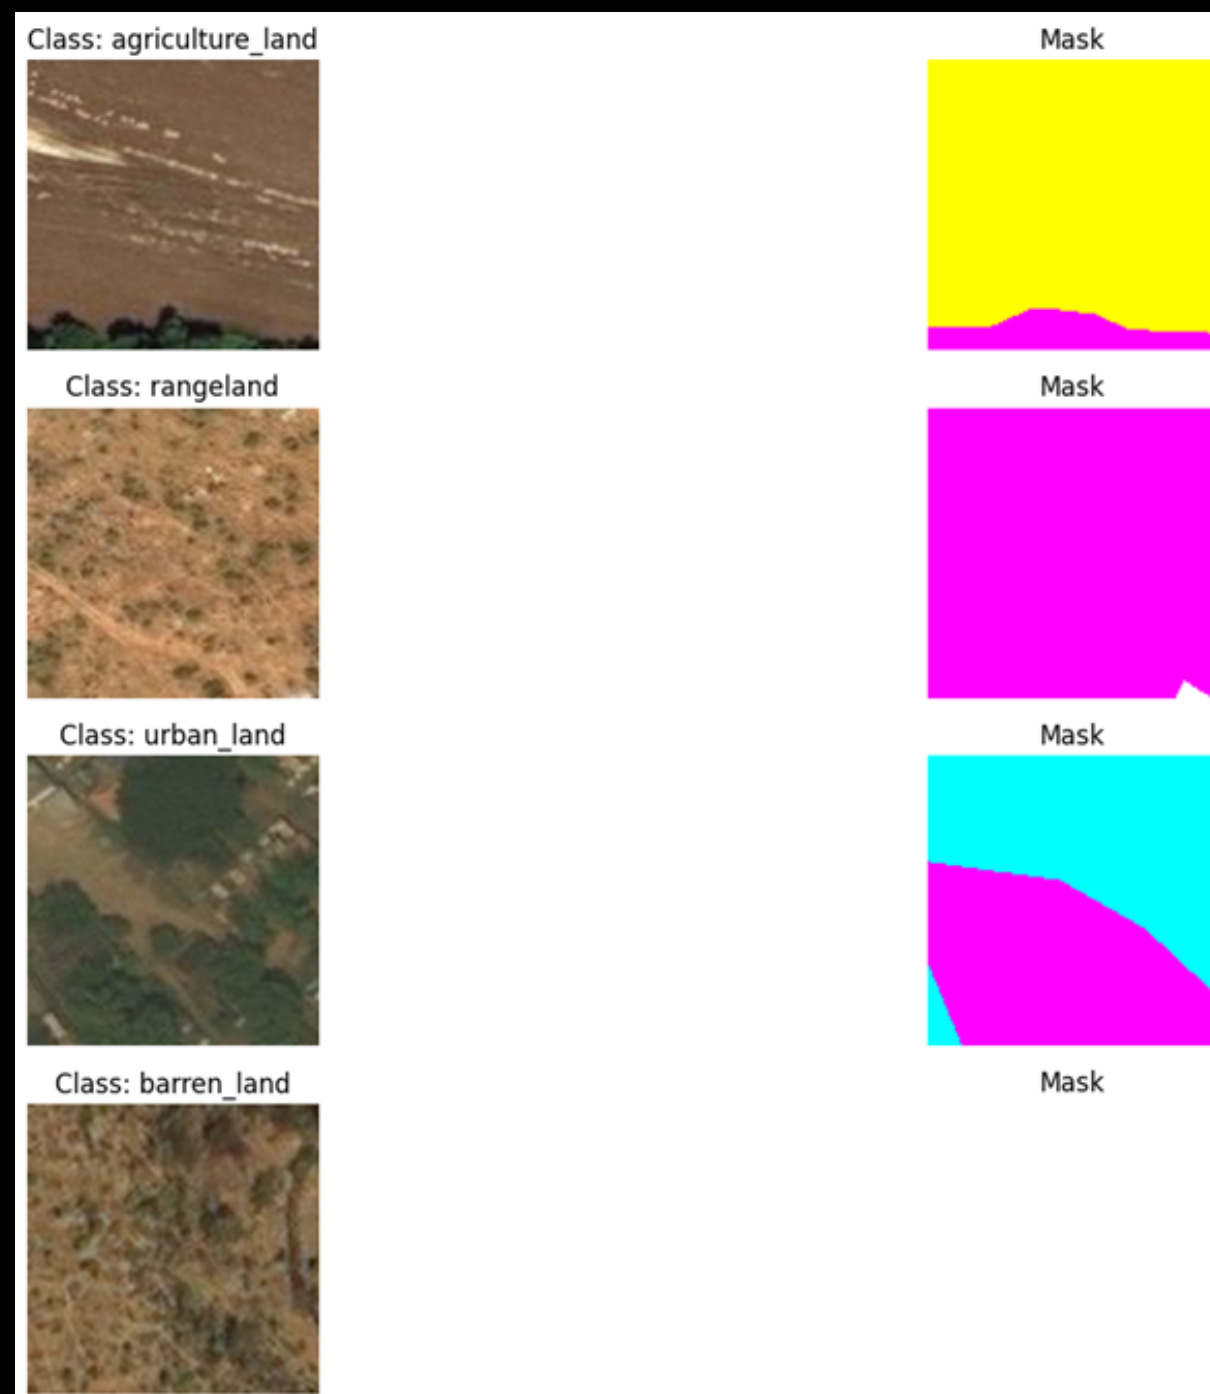


Distribución original



Distribución tiles 128x128


## S2. ANÁLISIS EXPLORATORIO (EDA)



- Ver notebook: *EDA\_DeepGlobe\_128.ipynb*

## S2. PRE-PROCESADO

- Decisión de balanceo



Condicionada por escasez de recursos:  
 $N^\circ \text{ muestras/clase} =$   
 $N^\circ \text{ muestras} (\min(\text{clase.n\_muestras}))$   
(excepto  $n^\circ$  de clase 'unknown')

~43k muestras

- Ver **notebook**:  
*Preprocess\_Transformers\_DeepGlobe\_128.ipynb*

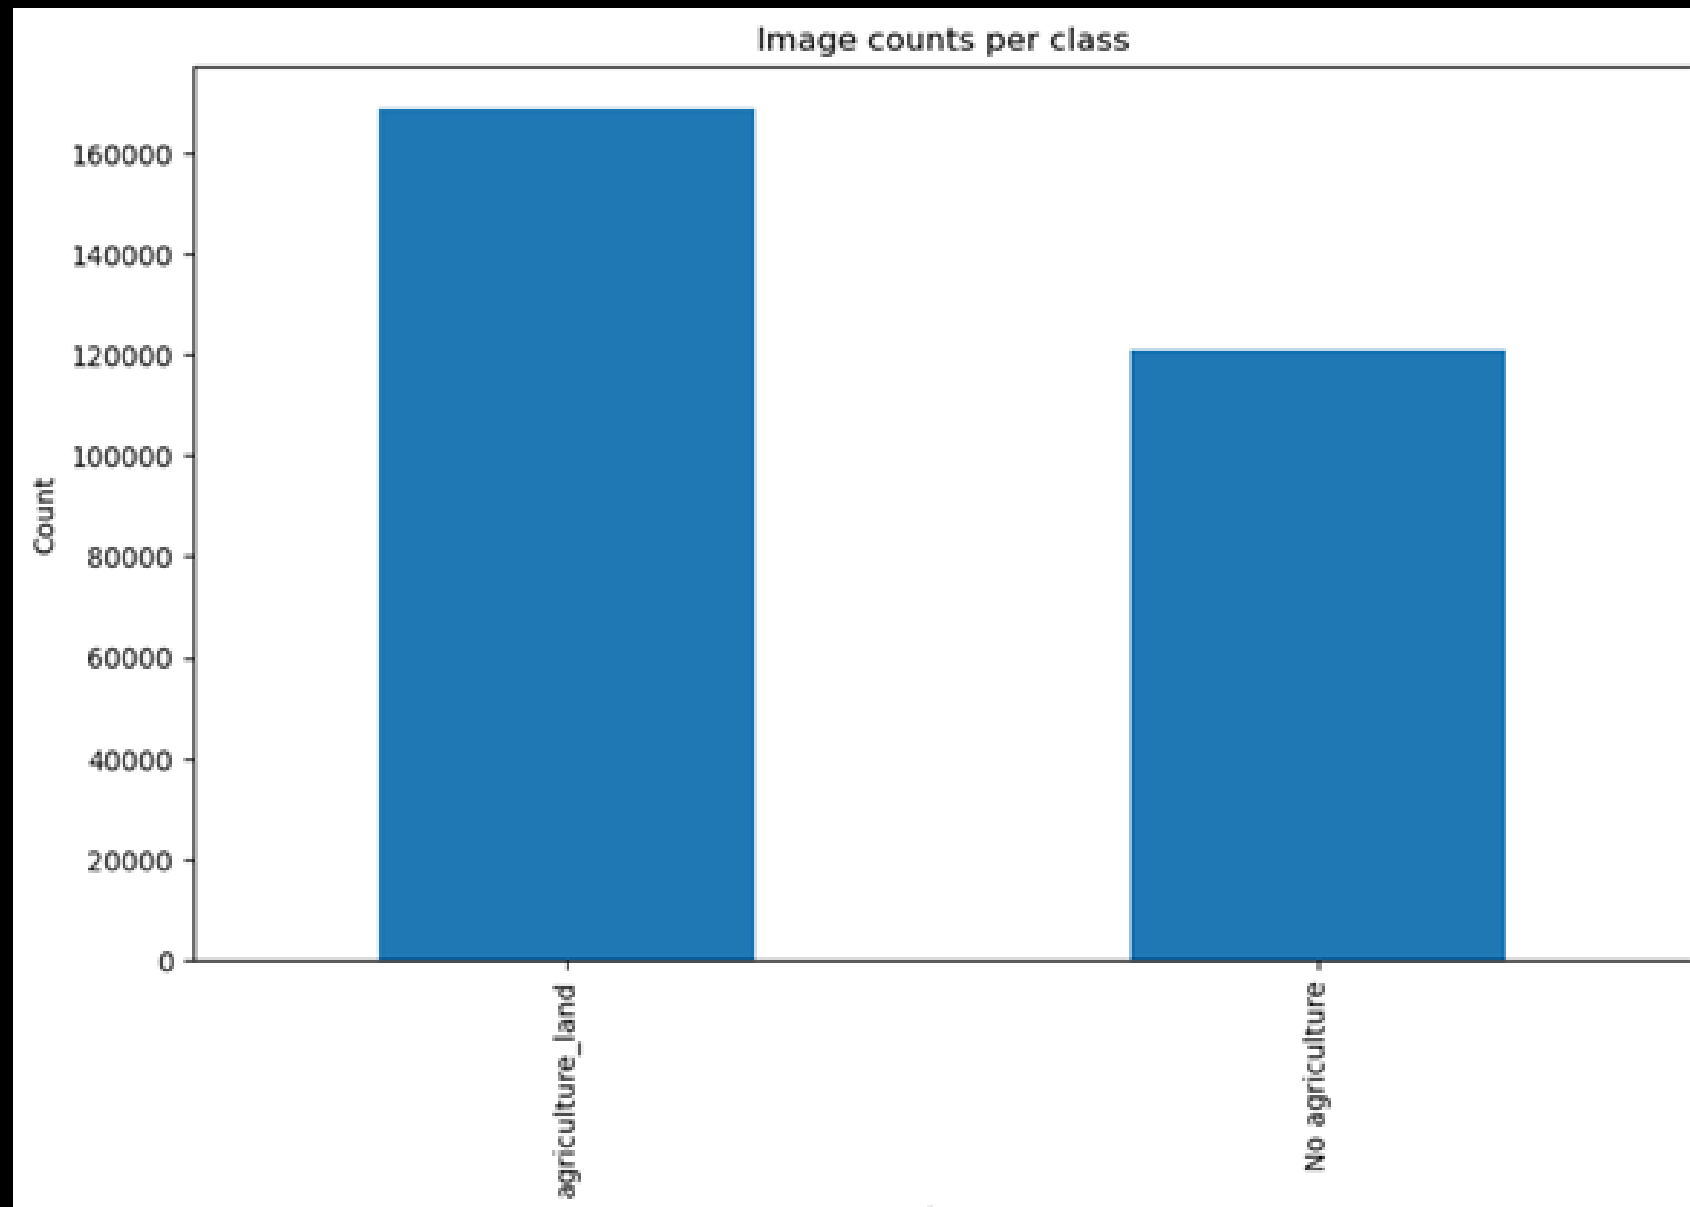
# S3. MODELADO Y EVALUACIÓN

## MODELO MULTICLASE DE CLASIFICACIÓN

- Vision Transformers (ViT)
  - Embedding extraction
- Dificultades con algunas clases
  - ¿Clase unknown?
  - ¿N° muestras?
  - Margen de mejora amplio
- Ver **notebook**:  
*Multiclass\_Model\_Transformers\_DeepGlobe\_128.ipynb*

	precision	recall	f1-score	support
0	0.91	0.31	0.46	1065
1	0.90	0.35	0.51	1044
2	0.94	0.61	0.74	1040
3	0.31	0.92	0.46	1093
4	1.00	0.59	0.74	27
5	0.93	0.71	0.80	1089
6	0.98	0.83	0.90	1093
accuracy			0.63	6451
macro avg	0.85	0.62	0.66	6451
weighted avg	0.83	0.63	0.65	6451

## S3. MODELO BINARIO DE CLASIFICACIÓN




Etiquetado binario



- Agriculture
- Not agriculture
  - Todas aquellas que no sean 'agriculture\_land'

## S3. MODELO BINARIO DE CLASIFICACIÓN


- 25k muestras/clase
- Vision Transformers (ViT)



con los resultados!

- Ver notebook:

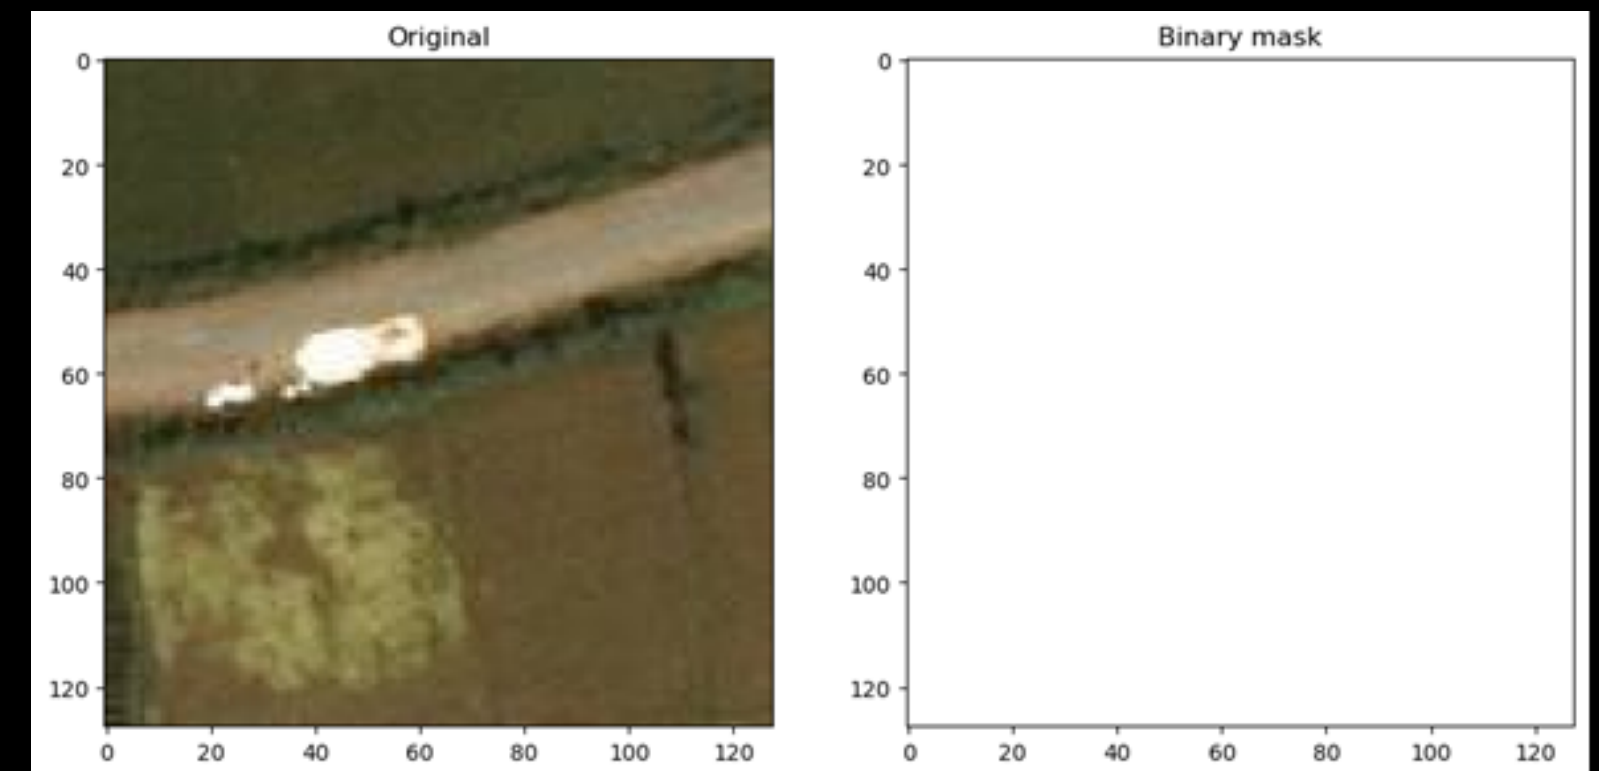
*Binary\_Classification\_Transformers\_DeepGlobe-128.ipynb*



	precision	recall	f1-score	support
0	0.83	0.90	0.86	3743
1	0.89	0.81	0.85	3757
accuracy			0.86	7500
macro avg	0.86	0.86	0.86	7500
weighted avg	0.86	0.86	0.86	7500

## S3. MODELO BINARIO DE SEGMENTACIÓN

- 40k muestras/clase
- CNN U-Net
- Muy poco entrenamiento
- Muy mejorable
  - Más muestras
  - Mas tiempo



```
80/80 [=====] - 375s 5s/step  
IoU Score (Validation): 0.6860715426499436
```

- Ver **notebook**: *Binary\_Segmentation\_128.ipynb*





## S3. FASE 2 - DIFERENCIACIÓN CULTIVOS VERDES Y SECOS

No tenemos etiquetas



¿Opciones?

- Aprendizaje no supervisado
- ¿Alternativa más rápida?

***Dominancia  
de color***

- Ver **notebook**: *Binary\_Segmentation\_128.ipynb*

## S3. FASE 2 - DIFERENCIACIÓN CULTIVOS VERDES Y SECOS



```
def max_intensity_avg(image):  
    b, g, r = cv2.split(image)  
    avg_intensity_b = b.mean()  
    avg_intensity_g = g.mean()  
    avg_intensity_r = r.mean()  
  
    dominant_channel_avg = 'Blue'  
    max_intensity = avg_intensity_b  
  
    if avg_intensity_g > max_intensity:  
        dominant_channel_avg = 'Green'  
        max_intensity = avg_intensity_g  
        coef_rg = avg_intensity_r / avg_intensity_g  
        if coef_rg > 1.09:  
            dominant_channel_avg = 'Red'  
  
    return dominant_channel_avg
```

Sprint 4 - Construcción maqueta visualización ...

Diseño frontend  
🕒 4 de oct. - 10 de oct. ≡

Construcción backend  
🕒 4 de oct. - 10 de oct. ≡

+ Añada una tarjeta 📅

Sprint 5 - Deploying maqueta GCC ...

Exploración opciones Deploy  
🕒 11 de oct. - 12 de oct. ≡

Deploy app  
🕒 12 de oct. - 17 de oct. ≡

+ Añada una tarjeta 📅

Sprint 6 - Generación informes y documentación ...

Generación informes y documentos  
🕒 18 de oct. - 24 de oct. ≡


+ Añada una tarjeta 📅

# S4. CONSTRUCCIÓN MAQUETA VISUALIZACIÓN

## FRONTEND



## BACKEND



• Ver archivos *app*

## S5. DEPLOYING MAQUETA GOOGLE CLOUD



- VM Debian 11 bullseye con IP externa fija
- App ejecutándose en VM
- Firewall con puerto 5000 abierto a internet para acceso a app

# S6. GENERACIÓN INFORMES Y DOCUMENTACIÓN


- Generación documentación
- Video maqueta
- Video presentación

Detección de estado de cultivos  
mediante remote sensing para  
mejora del despliegue de medios  
en incendios forestales




Alejandro Sáez Subero  
Data Scientist - Corporación Nacional Forestal





# DIFICULTADES Y DESAFÍOS


- Limitación de recursos
- Complejidad de la tarea



# **LIMITACIÓN DE RECURSOS**

- Problemas con la versión gratuita de Google Colab
  - Cierres de sesión
  - Sin GPU
- Trabajo con recursos locales con Jupyter Notebook
  - Limitar cantidad muestras y entrenamientos






# COMPLEJIDAD DE LA TAREA

- Elección de modelos
  - Diferencias balanceo de muestras entre modelos
    - Clase 'unknown'
    - Desbalanceo implícito en modelo binario
- Naturaleza de la tarea
  - Niveles de zoom
    - Difícil de abordar
  - Necesidad de altísima precisión en los bordes
    - Complejo en modelos de clasificación

# TAREAS PENDIENTES Y MEJORAS

- 3 líneas de trabajo para siguientes iteraciones:
  - Modelos binarios de segmentación
  - Mejora en los modelos de clasificación
  - Explorar posibilidades del Segment Anything Model (SAM) de Meta
  - Y un bonus...




## MODELOS BINARIOS DE SEGMENTACIÓN

- Desarrollar el modelo de segmentación binaria
  - Mayor cantidad de muestras
  - Búsqueda de hiperparámetros en modelo CNN
  - Construcción modelo Transformers
  - Entrenamiento más largo
  - Es probable que se cuente con Colab Pro próximamente

## MODELOS DE CLASIFICACIÓN

- Entrenamiento con más muestras
  - Sólo se ha utilizado ~15% de las disponibles
  - Pruebas con dataset con imágenes con las 12 bandas
  - Balanceo de las subclases dentro de la clase 'no\_agriculture'




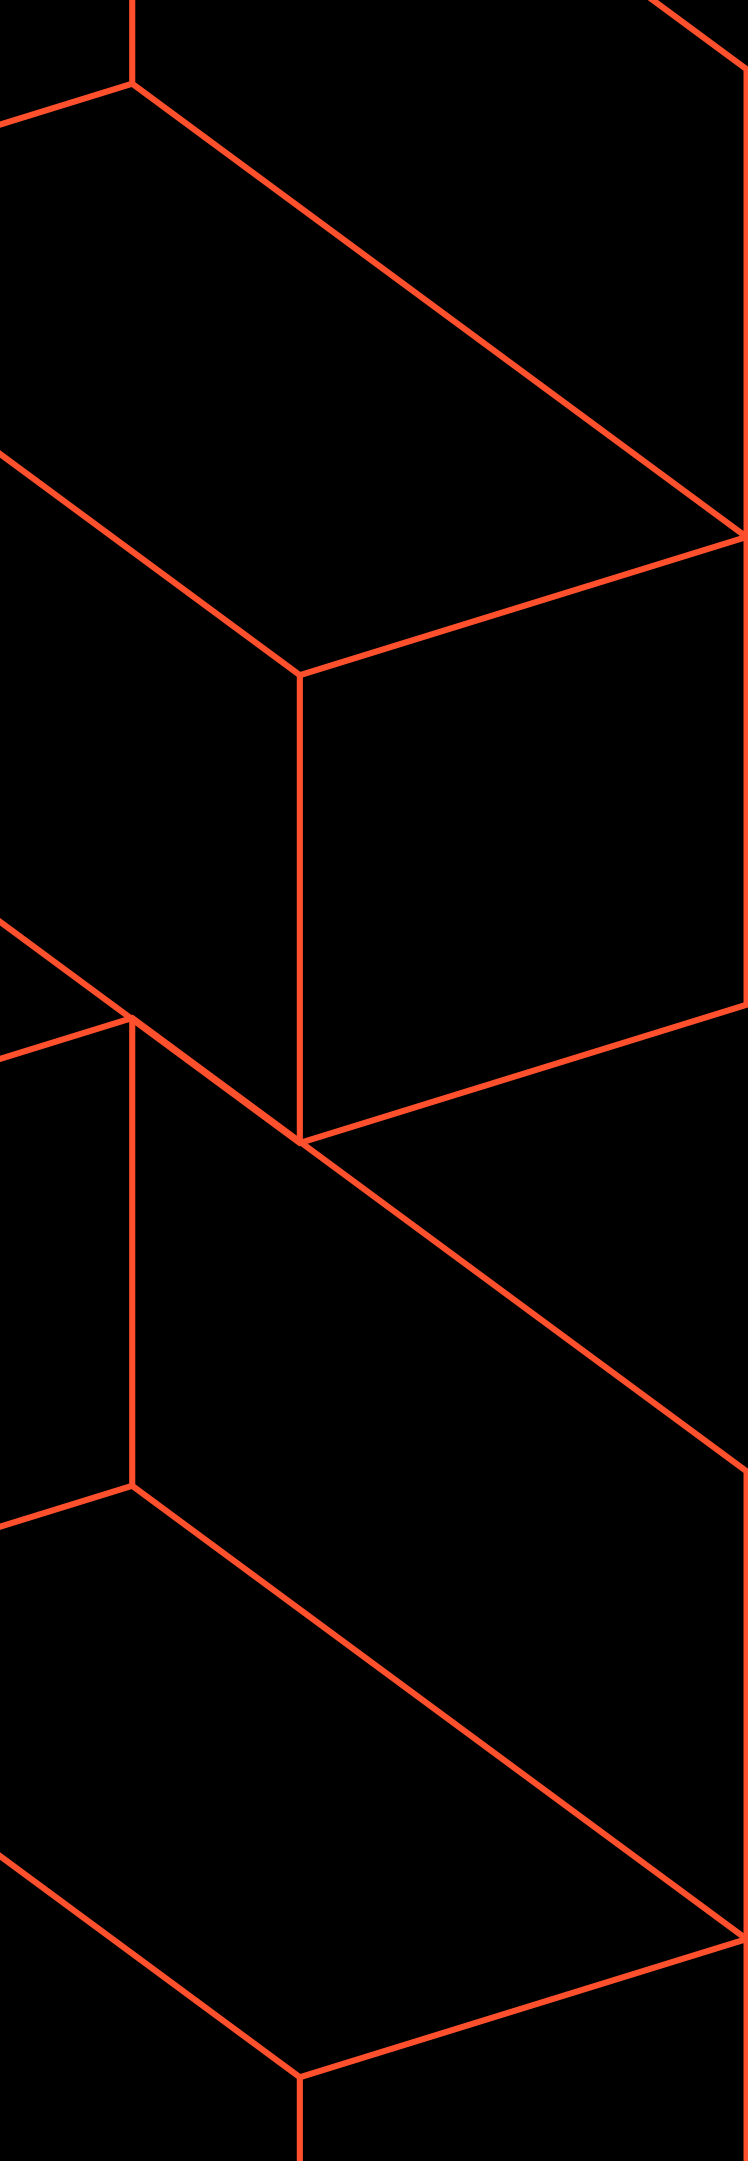
## SEGMENT ANYTHING MODEL (SAM)

- Explorar posibilidades de aplicar este modelo
  - Capaz de segmentar cualquier objeto en la imagen
  - Amplía posibilidades para proyectos que se deriven de este como:
    - Detección de construcciones en bosques (muy importante en incendios forestales)

## BONUS

- Proyecto paralelo
  - Dataset DeepGlobe se compone de imágenes con máscara e imágenes sin máscara
    - Etiquetado de las imágenes mediante aprendizaje semi-supervisado





# CONCLUSIONES

- Importante desafío
- Compendio del aprendizaje adquirido en el último año
- Necesidad y capacidad de ampliación de conocimientos e investigación
- Confianza para afrontar proyectos de envergadura
- Primera iteración del proyecto finalizada. Comienza segunda iteración

# AGRADECIMIENTOS

Muchas gracias a todos los profesores del bootcamp, que han aportado sustancialmente desde sus diferentes áreas y que, muy especialmente, han motivado a seguir aprendiendo, investigando y creciendo profesionalmente. También a KeepCoding, que ha posibilitado esta importante formación de forma estructurada y clara.

Por último, una mención especial a Ricardo Faúndez, que no se ha cansado de contestar a mis muchas dudas y preguntas, siempre con el mejor de los ánimos.